

KNN and curse of dimensionality

Motivation:

Khi số chiều dữ liệu tăng lên, độ phức tạp thuật toán cũng tăng theo cấp số nhân $O(n \times d)$.

Ảnh hưởng của dữ liệu đa chiều đến hiệu quả của KNN:

+ Tăng độ thưa thớt:

- Khi số chiều tăng lên, kích thước của không gian cũng tăng theo cấp số mũ. Ngoài ra việc có thêm các trọng số mới cũng gia tăng khoảng cách giữa các điểm 1 cách không cần thiết.

=> Giảm hiệu quả: Các trọng số không quan trọng có thể thêm noise/outlier vào bộ dữ liệu, làm ảnh hưởng đến kết quả của mô hình.

Solutions:

Các cách để giảm chiều dữ liệu:

+ PCA (Principal Component Analys) **unsupervised** :

-B1: Chuẩn hóa dữ liệu về Phân phối chuẩn:

- A mean of 0
- A standard deviation of 1

$$Z = \frac{X - \mu}{\sigma}$$

where:

- μ is the mean of independent features $\mu = \{\mu_1, \mu_2, \dots, \mu_m\}$
- σ is the standard deviation of independent features $\sigma = \{\sigma_1, \sigma_2, \dots, \sigma_m\}$

- Lúc này, các biến sẽ được **khác bao nhiêu độ lệch chuẩn so với giá trị trung bình** trong cùng feature với nhau, tránh trường hợp "Râu ông này cắm cằm bà kia". Ví dụ: 175cm ở Việt Nam được coi là cao, nhưng với người da trắng là trung bình/ thấp.


-B2: Tính ma trận tương quan

$$\text{cov}(x_1, x_2) = \frac{\sum_{i=1}^n (x_{1i} - \bar{x}_1)(x_{2i} - \bar{x}_2)}{n-1}$$

Where:

- $\bar{x}_1$ and $\bar{x}_2$ are the mean values of features x_1 and x_2
- n is the number of data points

Mục đích để xác định mối quan hệ giữa kết quả và feature, giúp PCA giữ lại những feature quan trọng.



Đây là kết quả của ma trận tương quan trong bài tập lớn môn Xác Suất và Thống kê chủ đề phân tích yếu tố ảnh hưởng đến kết quả là quảng cáo. Ma trận cho thấy mối quan hệ giữa các feature với nhau.

B3:

-Kiểm vector nào cho phương sai càng lớn thì sẽ càng quan trọng.

+LDA **supervised**:

Our aim to normalize the difference $|\hat{\mu}_1 - \hat{\mu}_2|$ to maximize the class separation. The scatter for samples of class c_1 is calculated as:

$$s_1^2 = \sum_{x_i \in c_1} (x_i - \mu_1)^2$$

Similarly for class c_2 :

$$s_2^2 = \sum_{x_i \in c_2} (x_i - \mu_2)^2$$

The goal is to maximize the ratio of the between-class scatter to the within-class scatter, which leads us to the following criteria:

$$J(v) = \frac{|\hat{\mu}_1 - \hat{\mu}_2|}{s_1^2 + s_2^2}$$

For the best separation we calculate the eigenvector corresponding to the highest eigenvalue of the scatter matrices $s_w^{-1} s_b$.

Việc của LDA đơn giản là tìm ra **1 ma trận trọng số để tạo ra feature mới** là *tổng hòa của các feature cũ* sao cho vẫn có khả năng phân biệt giữa class. Phải biết trước nhãn.

LDA cũng có thể dùng để giải bài toán phân loại.

Extra:

+Kernel PCA cho dữ liệu phi tuyến. Điểm yếu là chậm hơn PCA gốc.

+Graph kernel PCA : Dữ liệu cấu trúc manifold như single cell RNA, cánh tay máy

+NMF (Non negative matrix factorization): dùng cho dữ liệu tuyến tính không âm, sử dụng phương pháp ước lượng, tìm 2 ma trận có tích gần bằng với ma trận ban đầu thay vì phân rã ma trận .

+ Undercomplete Autoencoder : dùng deep learning để giảm chiều

+ GDA hay còn gọi là kernel LDA: cải tiến LDA cho dữ liệu phi tuyến

+ Ngoài ra còn t-SNE và UMAP nhưng chỉ được dùng để visualize data

Dataset:

Synthetic

```
from sklearn.datasets import make_classification
X, y = make_classification(
    n_samples=1000,
    n_features=20,
    n_informative=10,
    n_redundant=5,
    n_repeated=0,
    n_classes=2,
    random_state=42
)
```

Real :

Iris Species

có 4 feature, 3class, cơ bản để luyện tập

Wine dataset

Có 13 feature, 3 class

Breast Cancer Wisconsi trong scikit-learn:

```
from sklearn.datasets import load_breast_cancer
X, y = load_breast_cancer(return_X_y=True)
```

30 feature, 2 class

Parkinsons:

22 feature

Tài liệu tham khảo:

https://en.wikipedia.org/wiki/Dimensionality_reduction

<https://www.geeksforgeeks.org/machine-learning/ml-linear-discriminant-analysis/>

<https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbors-and-curse-of-dimensionality/>

<https://www.geeksforgeeks.org/deep-learning/undercomplete-autoencoder/>

https://www.youtube.com/watch?v=_UVHneBUBW0