



Ảnh hưởng của các phương pháp giảm chiều trong mô hình KNN

The Harmony / Minh Khoa - Quang Nhật - Đức Tuấn - Văn Lực - Lưu Bang

I. Tóm tắt nghiên cứu

Curse of dimensionality là một trong những thách thức đối với các mô hình phân loại dựa trên khoảng cách, đặc biệt là thuật toán K-Nearest Neighbors (KNN) khi xử lý dữ liệu có số chiều lớn. Mặc dù nhiều phương pháp giảm chiều đã được đề xuất, hiệu quả của PCA, LDA và cách kết hợp tuần tự hai phương pháp này vẫn cần được đánh giá trên các bộ dữ liệu có đặc điểm khác nhau.

Nghiên cứu này đánh giá ảnh hưởng của giảm chiều đối với KNN thông qua bốn cấu hình gồm KNN trên dữ liệu đã chuẩn hóa, PCA-KNN, LDA-KNN và PCA-LDA-KNN. PCA được sử dụng để tạo biểu diễn có số chiều thấp hơn theo tiêu chí phương sai, trong khi LDA sử dụng nhân để tìm các hướng có khả năng phân biệt lớp. Bốn cấu hình được so sánh trên cùng các fold nhằm xác định đóng góp riêng của PCA, LDA và việc áp dụng PCA trước LDA.

Các thí nghiệm được thực hiện trên ba bộ dữ liệu gồm *Breast Cancer*, *LFW People* và *MNIST*, sử dụng 3-fold stratified cross-validation. Các tiêu chí đánh giá gồm accuracy, macro-precision, macro-recall, macro-F1 và thời gian truy vấn trên mỗi mẫu. Trên *Breast Cancer*, KNN trên dữ liệu chuẩn hóa đạt accuracy trung bình cao nhất là 0.9649 ± 0.0152 , nhưng chênh lệch giữa các cấu hình nhỏ so với biến thiên giữa các fold. Trên *LFW People*, PCA-LDA-KNN đạt kết quả cao nhất với accuracy 0.5174 ± 0.0125 và macro-F1 0.3901 ± 0.0053 . Trên *MNIST*, PCA-KNN đạt kết quả tốt nhất với accuracy 0.9580 ± 0.0004 và macro-F1 0.9575 ± 0.0004 . Giảm chiều cũng làm giảm thời gian truy vấn của brute-force KNN, đặc biệt trên *LFW People* và *MNIST*.

Kết quả cho thấy hiệu quả của giảm chiều phụ thuộc vào đặc điểm của từng bộ dữ liệu và không tồn tại một cấu hình tối ưu cho mọi trường hợp. PCA-LDA phù hợp nhất với *LFW People*, PCA đơn lẻ phù hợp hơn với *MNIST*, còn *Breast Cancer* không cho thấy lợi ích ổn định từ giảm chiều. Nghiên cứu cung cấp bằng chứng thực nghiệm để lựa chọn phương pháp giảm chiều dựa trên cả hiệu năng phân loại và chi phí truy vấn trước khi áp dụng KNN cho dữ liệu nhiều chiều.

Mục lục

I.	Tóm tắt nghiên cứu	1
II.	Giới thiệu	4
III.	Bài toán nghiên cứu	5
IV.	Tổng quan nghiên cứu liên quan	6
V.	Phương pháp nghiên cứu	7
V.1.	Các cấu hình được so sánh	7
V.2.	Giảm chiều bằng PCA và LDA	8
V.3.	Số chiều của các phép chiếu	8
V.4.	Luồng xử lý trong mỗi fold	8
V.5.	Thiết lập cross-validation	9
V.6.	Đánh giá thời gian truy vấn	9
V.7.	Lý do lựa chọn thiết kế thực nghiệm	9
VI.	Dữ liệu và thiết lập thí nghiệm (Experiments)	10
VI.1.	Dataset	10
VII.	Kết quả thí nghiệm (Results)	11
VII.1.	Tổng hợp kết quả cross-validation	11
VII.2.	Kết quả trên Breast Cancer	11
VII.3.	Kết quả trên LFW People	12
VII.4.	Kết quả trên MNIST	12
VII.5.	Thời gian truy vấn	12
VIII.	Thảo luận (Discussion)	12
VIII.1.	Trả lời các câu hỏi nghiên cứu	12
VIII.2.	Diễn giải các kết quả chính	13
VIII.3.	Liên hệ với các nghiên cứu trước	14
VIII.4.	Đánh đổi giữa hiệu năng và thời gian truy vấn	14
VIII.5.	Giới hạn của kết quả	14
IX.	Phân tích lỗi và hạn chế	15

IX.1.	Phân tích xu hướng lỗi mô hình	15
IX.2.	Hạn chế của các phương pháp giảm chiều	16
IX.3.	Hạn chế của thiết lập thí nghiệm	16
X.	Tái lập kết quả và mã nguồn (Replicate the results)	17
X.1.	Cài đặt môi trường	17
X.2.	Chạy lại thí nghiệm	17
X.3.	Các file kết quả	18
X.4.	Lưu ý về khả năng tái lập	18
XI.	Kết luận và hướng nghiên cứu tiếp theo	19
XI.1.	Kết luận	19
XI.2.	Hướng nghiên cứu tiếp theo	19
XII.	Tài liệu tham khảo	21
Phụ lục		23

II. Giới thiệu

Nghiên cứu này thuộc lĩnh vực **Machine Learning**, cụ thể là bài toán **phân loại dữ liệu (classification)** trên không gian đặc trưng nhiều chiều. Trong nhiều ứng dụng thực tiễn như nhận dạng khuôn mặt, chẩn đoán y khoa hay nhận dạng chữ viết tay, dữ liệu thường có số lượng đặc trưng rất lớn. Điều này gây ra nhiều thách thức cho các thuật toán học máy, đặc biệt là các phương pháp phân loại dựa trên khoảng cách như *K-Nearest Neighbors* (KNN).

Một trong những vấn đề nổi bật của dữ liệu nhiều chiều là hiện tượng *curse of dimensionality*. Khi số chiều tăng lên, khoảng cách giữa các điểm dữ liệu có thể trở nên kém phân biệt, làm giảm độ tin cậy của quan hệ láng giềng mà KNN sử dụng. Đồng thời, dữ liệu có nhiều đặc trưng dư thừa hoặc không liên quan làm gia tăng chi phí tính toán và có thể ảnh hưởng tiêu cực đến hiệu quả phân loại. Vì vậy, giảm số chiều trước khi thực hiện phân loại là một hướng tiếp cận thường được sử dụng để tạo biểu diễn gọn hơn và giảm chi phí tính khoảng cách.

Nhiều phương pháp giảm chiều đã được đề xuất, trong đó Principal Component Analysis (PCA) là phương pháp phổ biến để giảm sự dư thừa giữa các đặc trưng bằng cách chiếu dữ liệu lên các thành phần chính có phương sai lớn. Tuy nhiên, PCA là phương pháp không giám sát nên không tận dụng thông tin nhãn lớp, và các hướng có phương sai lớn chưa chắc chứa nhiều thông tin nhất cho phân loại. Ngược lại, Linear Discriminant Analysis (LDA) sử dụng thông tin nhãn để tìm không gian đặc trưng có khả năng phân tách các lớp tốt hơn, nhưng hiệu quả của LDA có thể bị ảnh hưởng khi dữ liệu có số chiều lớn so với số mẫu. Do đó, việc áp dụng PCA trước LDA có thể tạo một biểu diễn đầu vào gọn hơn cho LDA, nhưng hiệu quả của cách kết hợp này cần được kiểm chứng thay vì giả định trước.

Mặc dù đã có nhiều nghiên cứu áp dụng PCA hoặc LDA riêng lẻ, cũng như kết hợp hai phương pháp này, hiệu quả của từng cấu hình giảm chiều vẫn phụ thuộc đáng kể vào đặc điểm của từng bộ dữ liệu. Trong phạm vi các tài liệu được tổng quan, chưa có kết luận thống nhất về việc PCA, LDA hoặc PCA-LDA đóng góp như thế nào khi kết hợp với KNN và liệu thứ hạng giữa các cấu hình có nhất quán trên những bộ dữ liệu có số mẫu, số chiều và số lớp khác nhau hay không.

Xuất phát từ khoảng trống trên, nghiên cứu này tập trung đánh giá ảnh hưởng của các phương pháp giảm chiều đối với hiệu quả phân loại của KNN. Cụ thể, nhóm xây dựng và so sánh bốn cấu hình gồm KNN trên dữ liệu đã chuẩn hóa, PCA-KNN, LDA-KNN và PCA-LDA-KNN trên ba bộ dữ liệu *Breast Cancer*, *LFW People* và *MNIST*. Các cấu hình được đánh giá trên cùng các fold bằng 3-fold stratified cross-validation thông qua accuracy, macro-precision, macro-recall và macro-F1. Thời gian truy vấn của KNN cũng được đo để xem xét ảnh hưởng của số chiều biểu diễn đến chi phí tìm kiếm láng giềng.

Đóng góp chính của nghiên cứu gồm: (i) xây dựng baseline KNN trên dữ liệu đã chuẩn hóa để làm cơ sở so sánh; (ii) đánh giá thực nghiệm ba cấu hình giảm chiều PCA-KNN, LDA-KNN và PCA-LDA-KNN trên các bộ dữ liệu có đặc điểm khác nhau bằng cùng một quy trình cross-validation; (iii) phân tích những trường hợp mà giảm chiều cải thiện, không làm thay đổi rõ rệt hoặc làm suy giảm hiệu năng phân loại; và (iv) đánh giá sự đánh đổi giữa hiệu năng phân loại, số chiều biểu diễn và thời gian truy vấn của KNN. Các kết quả cung cấp bằng chứng thực nghiệm cho việc lựa chọn phương pháp giảm chiều theo đặc điểm của từng bài toán, thay vì giả định một cấu hình luôn tối ưu.

III. Bài toán nghiên cứu

Tên bài toán: Đánh giá ảnh hưởng của PCA và LDA đối với hiệu năng phân loại và thời gian truy vấn của KNN.

Nghiên cứu xem xét bài toán phân loại có giám sát trên ba bộ dữ liệu Breast Cancer, LFW People và MNIST. Thay vì đề xuất một thuật toán giảm chiều mới, nghiên cứu thực hiện ablation study để so sánh có kiểm soát bốn cấu hình:

1. KNN trên dữ liệu đã chuẩn hóa;
2. PCA-KNN;
3. LDA-KNN;
4. PCA-LDA-KNN.

Input: Ma trận đặc trưng $X \in \mathbb{R}^{N \times d}$ và vector nhãn $\mathbf{y} \in \mathbb{R}^N$. Mỗi bộ dữ liệu có số mẫu, số đặc trưng và số lớp khác nhau. Trong từng fold, bước chuẩn hóa và các phép giảm chiều chỉ được fit trên training fold, sau đó được dùng để biến đổi test fold.

Output: Nhãn dự đoán của KNN cho các mẫu trong test fold, các metric phân loại của từng cấu hình và thời gian truy vấn trên mỗi mẫu. Kết quả được tổng hợp dưới dạng giá trị trung bình và độ lệch chuẩn qua ba fold.

Mục tiêu nghiên cứu: Xác định PCA, LDA và việc áp dụng tuần tự PCA-LDA làm thay đổi hiệu năng của KNN như thế nào so với baseline; xác định cấu hình đạt kết quả tốt nhất trên từng bộ dữ liệu; và đánh giá liệu ảnh hưởng của giảm chiều có nhất quán giữa các bộ dữ liệu hay phụ thuộc vào đặc điểm dữ liệu.

Tiêu chí đánh giá: Accuracy, macro-precision, macro-recall, macro-F1 và thời gian thực hiện `KNN.predict` trên mỗi mẫu. Bốn cấu hình sử dụng cùng các fold của 3-fold stratified cross-validation, cùng mô hình KNN với $k = 5$ và cùng hệ metric để bảo đảm khả năng so sánh trực tiếp.

Phạm vi kết luận: Nghiên cứu chỉ so sánh bốn cấu hình tại các số thành phần PCA và LDA được cố định trước. Thí nghiệm không thay đổi số chiều đầu vào theo nhiều mức có kiểm soát và không đo trực tiếp hiện tượng tập trung khoảng cách. Vì vậy, kết quả không được dùng để kết luận PCA hoặc LDA đã loại bỏ lời nguyên số chiều; chúng chỉ cho thấy tác động thực nghiệm của các biểu diễn giảm chiều đối với KNN trong phạm vi ba bộ dữ liệu và thiết lập đã lựa chọn.

Từ bài toán trên, nghiên cứu kiểm tra ba nhận định. Thứ nhất, một phương pháp giảm chiều có thể cải thiện KNN trên bộ dữ liệu này nhưng làm giảm hiệu năng trên bộ dữ liệu khác. Thứ hai, PCA-LDA không nhất thiết tốt hơn PCA hoặc LDA riêng lẻ. Thứ ba, việc giảm số chiều có thể rút ngắn thời gian tìm kiếm láng giềng của KNN nhưng không bảo đảm cải thiện hiệu năng phân loại.

IV. Tổng quan nghiên cứu liên quan

KNN trong không gian nhiều chiều. KNN phân loại mẫu dựa trên nhãn của các mẫu huấn luyện gần nhất, nên hiệu năng phụ thuộc trực tiếp vào cách đo khoảng cách [1]. Beyer và cộng sự chỉ ra rằng khoảng cách đến điểm gần nhất có thể tiến gần khoảng cách đến điểm xa nhất khi số chiều tăng, làm giảm ý nghĩa của quan hệ láng giềng [2]. Aggarwal, Hinneburg và Keim cho thấy mức độ tập trung khoảng cách còn phụ thuộc vào chuẩn L_p [3], trong khi François, Wertz và Verleysen phân tích hiện tượng này bằng phương sai tương đối và cho thấy nó không chỉ xuất phát từ kích thước hữu hạn của mẫu dữ liệu [4].

Giảm chiều bằng PCA và LDA. PCA tạo các thành phần chính nhằm giữ lại phần lớn phương sai của dữ liệu mà không sử dụng nhãn [5], [6]. Phương pháp này có thể giảm số chiều cũng như số phép toán và thời gian tính khoảng cách, nhưng các thành phần có phương sai lớn chưa chắc chứa thông tin hữu ích cho phân loại. Ngược lại, LDA sử dụng nhãn để tìm không gian chiều làm tăng sự khác biệt giữa các nhóm cần dự đoán [7]. Vì hai phương pháp tối ưu theo các tiêu chí khác nhau, hiệu quả của chúng đối với KNN phụ thuộc vào đặc điểm dữ liệu và số chiều được giữ lại.

Kết hợp PCA và LDA. Các nghiên cứu của Swets và Weng, cũng như Belhumeur và cộng sự, đã sử dụng PCA để giảm số chiều trước khi áp dụng LDA nhằm tìm các trục chiếu giúp những nhóm nhãn được tách biệt rõ ràng hơn [8], [9]. Tuy nhiên, PCA có thể loại bỏ những trục có phương sai thấp nhưng hữu ích cho phân loại, và Martínez cùng Kak cho thấy ưu thế của PCA hoặc LDA không mang tính tuyệt đối; trong trường hợp tập huấn luyện nhỏ, PCA có thể đạt kết quả tốt hơn LDA [10]. Do đó, PCA, LDA và PCA-LDA cần được đánh giá trên cùng dữ liệu và nhiều mức số chiều trước khi kết luận phương pháp nào hỗ trợ KNN tốt hơn.

Các so sánh thực nghiệm với KNN. Taufiqurrahman, Nababan và Efendi đã so sánh KNN không giảm chiều, PCA-KNN và LDA-KNN trên ba bộ dữ liệu Arrhythmia, ISOLET và CNAE-9. Trong thiết lập của nghiên cứu này, LDA-KNN nhìn chung đạt kết quả tốt hơn PCA-KNN trên các bộ dữ liệu có hơn 100 đặc trưng; tuy nhiên, nghiên cứu không đánh giá cấu hình tuần tự PCA-LDA-KNN [11]. Zhang và cộng sự đánh giá KNN, PCA-KNN và PCA-LDA-KNN trên 38 mẫu hạch bạch huyết trong bài toán chẩn đoán di căn ung thư dạ dày. Accuracy của PCA-LDA-KNN thay đổi từ 77,89% trước chuẩn hóa lên 96,33% sau chuẩn hóa, cho thấy kết quả còn phụ thuộc mạnh vào quy trình tiền xử lý [12]. Hai nghiên cứu này cung cấp bằng chứng thực nghiệm quan trọng, nhưng chưa tạo thành một phép so sánh đồng thời cả bốn cấu hình trong cùng một quy trình đánh giá.

Khoảng trống nghiên cứu. Các công trình trên đã làm rõ hiện tượng khoảng cách trở nên kém phân biệt trong không gian nhiều chiều, nguyên lý của PCA và LDA, đồng thời cung cấp một số so sánh thực nghiệm giữa các cấu hình giảm chiều với KNN. Tuy nhiên, trong phạm vi tài liệu được tổng quan, các nghiên cứu chưa đồng thời đánh giá bốn cấu hình gồm KNN trên dữ liệu đã chuẩn hóa, PCA-KNN, LDA-KNN và PCA-LDA-KNN trong cùng một quy trình kiểm soát trên những bộ dữ liệu khác nhau rõ rệt về số mẫu, số đặc trưng và số nhóm nhãn. Sự khác biệt về dữ liệu, tiền xử lý, cấu hình KNN và hệ thống metric khiến kết quả giữa các nghiên cứu khó được so sánh trực tiếp. Vì vậy, ba vấn đề vẫn cần được xem xét trong cùng một thiết lập: đóng góp riêng của PCA và LDA; lợi ích hoặc bất lợi của việc áp dụng tuần tự PCA-LDA; và mức độ phụ thuộc của các kết quả này vào đặc điểm dữ liệu.

Định hướng nghiên cứu hiện tại. Nghiên cứu này không đề xuất một thuật toán giảm chiều mới mà thực hiện một phép so sánh có kiểm soát giữa bốn cấu hình: KNN trên dữ liệu đã chuẩn hóa, PCA-KNN, LDA-KNN và PCA-LDA-KNN. Các cấu hình được đánh giá trên cùng các fold, cùng mô hình KNN và cùng hệ thống metric gồm accuracy, macro-precision, macro-recall và macro-F1. Thí nghiệm được thực hiện trên Breast Cancer, LFW People và MNIST, là ba bộ dữ liệu khác nhau về số mẫu, số đặc trưng và số nhóm nhãn.

Từ khoảng trống trên, nghiên cứu tập trung trả lời các câu hỏi sau:

- **RQ1:** Trong bốn cấu hình KNN, PCA-KNN, LDA-KNN và PCA-LDA-KNN, cấu hình nào đạt hiệu năng tốt nhất trên từng bộ dữ liệu?
- **RQ2:** Việc sử dụng riêng PCA, riêng LDA hoặc kết hợp PCA với LDA làm thay đổi hiệu năng của KNN như thế nào so với khi sử dụng dữ liệu gốc đã chuẩn hóa?
- **RQ3:** Ảnh hưởng của các phương pháp giảm chiều có nhất quán trên Breast Cancer, LFW People và MNIST hay phụ thuộc vào đặc điểm của từng bộ dữ liệu?

Các câu hỏi trên giới hạn kết luận của nghiên cứu trong phạm vi so sánh bốn cấu hình trên ba bộ dữ liệu được lựa chọn. Nghiên cứu không mặc định PCA-LDA luôn là cấu hình tối ưu mà xem xét cả những trường hợp trong đó một bước giảm chiều không cải thiện hoặc làm giảm hiệu năng của KNN.

V. Phương pháp nghiên cứu

Phần này trình bày bốn cấu hình được sử dụng để đánh giá ảnh hưởng của PCA và LDA đối với KNN, quy trình xử lý dữ liệu, thiết lập cross-validation và các tiêu chí đánh giá. Nghiên cứu không xem PCA-LDA là một thuật toán mới hoặc mặc định đây là cấu hình tốt nhất, mà thực hiện ablation study để so sánh đóng góp của từng bước giảm chiều.

V.1. Các cấu hình được so sánh

Bốn cấu hình được đánh giá gồm:

1. **KNN:** Standardization $\rightarrow$ KNN.
2. **PCA-KNN:** Standardization $\rightarrow$ PCA $\rightarrow$ KNN.
3. **LDA-KNN:** Standardization $\rightarrow$ LDA $\rightarrow$ KNN.
4. **PCA-LDA-KNN:** Standardization $\rightarrow$ PCA $\rightarrow$ LDA $\rightarrow$ KNN.

Cấu hình KNN trên dữ liệu đã chuẩn hóa được sử dụng làm baseline. Ba cấu hình còn lại cho phép đánh giá riêng ảnh hưởng của PCA, ảnh hưởng của LDA và ảnh hưởng của việc áp dụng tuần tự PCA-LDA. Tất cả cấu hình sử dụng cùng một mô hình KNN với $k = 5$, trọng số đồng đều, khoảng cách Euclidean và phương pháp tìm kiếm brute force.

V.2. Giảm chiều bằng PCA và LDA

PCA là phương pháp giảm chiều không giám sát, tìm các trục trực giao sao cho phương sai của dữ liệu chiếu được giữ lại nhiều nhất. Với vector đặc trưng đã chuẩn hóa $\mathbf{x}_s \in \mathbb{R}^d$, phép chiếu PCA được biểu diễn bởi:

$$\mathbf{y} = W_{\text{PCA}}^T \mathbf{x}_s, \quad \mathbf{y} \in \mathbb{R}^k, \quad (1)$$

trong đó $W_{\text{PCA}} \in \mathbb{R}^{d \times k}$ chứa k trục thành phần chính. PCA có thể loại bỏ một số hướng dư thừa và giảm số phép tính khoảng cách của KNN, nhưng các hướng có phương sai lớn không nhất thiết là những hướng hữu ích nhất cho phân loại.

LDA là phương pháp có giám sát, sử dụng nhãn lớp để tìm không gian chiếu làm tăng mức phân tách giữa các lớp so với độ phân tán trong từng lớp. Với dữ liệu đầu vào $\mathbf{u}$, phép chiếu LDA được viết dưới dạng:

$$\mathbf{z} = W_{\text{LDA}}^T \mathbf{u}, \quad \mathbf{z} \in \mathbb{R}^m, \quad (2)$$

trong đó số chiều đầu ra thỏa mãn $m \leq C - 1$, với C là số lớp. Trong cấu hình LDA-KNN, $\mathbf{u} = \mathbf{x}_s$; trong cấu hình PCA-LDA-KNN, $\mathbf{u} = \mathbf{y}$.

Đối với cấu hình PCA-LDA-KNN, hai phép chiếu được áp dụng tuần tự:

$$\mathbf{z} = W_{\text{LDA}}^T W_{\text{PCA}}^T \mathbf{x}_s. \quad (3)$$

PCA được đặt trước LDA nhằm giảm số chiều đầu vào của LDA. Thiết lập này có thể hữu ích khi số đặc trưng lớn so với số mẫu, nhưng cũng có nguy cơ loại bỏ những hướng có phương sai thấp nhưng chứa thông tin phân biệt lớp. Vì vậy, hiệu quả của PCA-LDA được kiểm tra bằng thực nghiệm thay vì được giả định trước.

PCA được cài đặt bằng `sklearn.decomposition.PCA` với `svd_solver="randomized"`. LDA được cài đặt bằng `LinearDiscriminantAnalysis` của `scikit-learn` với `solver="svd"`, qua đó không yêu cầu nghịch đảo trực tiếp ma trận phân tán trong lớp.

V.3. Số chiều của các phép chiếu

Để duy trì khả năng đối chiếu với thiết lập ban đầu, số thành phần PCA được cố định ở 8 đối với Breast Cancer, 100 đối với LFW People và 57 đối với MNIST. Số thành phần LDA tương ứng là 1, 61 và 9, đồng thời luôn bị giới hạn bởi số chiều đầu vào và $C - 1$.

Các giá trị này không được tối ưu bằng cross-validation trong nghiên cứu hiện tại. Vì vậy, kết quả phản ánh hiệu năng của các cấu hình tại những số chiều đã lựa chọn, không chứng minh rằng đây là số thành phần tối ưu cho từng bộ dữ liệu.

V.4. Luồng xử lý trong mỗi fold

Quy trình xử lý được thực hiện độc lập trong từng fold theo các bước sau:

1. Chia dữ liệu thành training fold và test fold bằng stratified cross-validation.
2. Fit `StandardScaler` trên training fold, sau đó dùng cùng scaler để biến đổi test fold.
3. Fit PCA hoặc LDA trên training fold tùy theo cấu hình, sau đó chỉ thực hiện phép biến đổi trên test fold.
4. Huấn luyện KNN trên biểu diễn của training fold và dự đoán nhãn của test fold.
5. Tính các metric phân loại trên test fold.

Việc fit toàn bộ bước chuẩn hóa và giảm chiều riêng trên training fold giúp tránh data leakage từ test fold vào quá trình xây dựng biểu diễn dữ liệu. Bốn cấu hình được đánh giá trên cùng các fold để tạo điều kiện so sánh trực tiếp.

V.5. Thiết lập cross-validation

Thí nghiệm sử dụng 3-fold stratified cross-validation với `shuffle=True` và `random_state=42`. Stratification duy trì gần đúng tỉ lệ các lớp trong mỗi fold, đặc biệt cần thiết đối với LFW People do số lớp lớn và số mẫu giữa các lớp không đồng đều.

Với mỗi cấu hình, nghiên cứu báo cáo giá trị trung bình và độ lệch chuẩn qua ba fold của bốn metric: accuracy, macro-precision, macro-recall và macro-F1. Các macro metric tính metric riêng cho từng lớp rồi lấy trung bình không trọng số, nhờ đó hạn chế việc kết quả bị chi phối hoàn toàn bởi các lớp có nhiều mẫu.

Thí nghiệm hiện tại chỉ sử dụng một lần 3-fold cross-validation và không thực hiện repeated cross-validation. Do đó, độ lệch chuẩn được dùng để mô tả biến thiên giữa ba fold, không được xem là bằng chứng kiểm định thống kê về sự khác biệt giữa các pipeline.

V.6. Đánh giá thời gian truy vấn

Ngoài hiệu năng phân loại, nghiên cứu đo thời gian dự đoán của KNN nhằm đánh giá ảnh hưởng của số chiều biểu diễn đến chi phí tìm kiếm láng giềng. Thời gian được đo trên fold đầu tiên với tối đa 200 mẫu truy vấn. Sau một lượt chạy khởi động, phép dự đoán được lặp lại năm lần và giá trị trung vị được quy đổi thành mili giây trên mỗi mẫu.

Phép đo này chỉ bao gồm thời gian thực hiện `KNN.predict` trên dữ liệu đã được biến đổi, không bao gồm thời gian chuẩn hóa, fit PCA, fit LDA hoặc biến đổi mẫu mới. Vì thời gian tuyệt đối phụ thuộc vào phần cứng và trạng thái của môi trường Colab, kết quả được sử dụng chủ yếu để so sánh tương đối giữa các cấu hình trong cùng môi trường thực nghiệm.

V.7. Lý do lựa chọn thiết kế thực nghiệm

PCA và LDA đại diện cho hai tiêu chí giảm chiều khác nhau: PCA giữ lại phương sai mà không sử dụng nhãn, trong khi LDA sử dụng nhãn để tìm các hướng phân biệt lớp. Việc so sánh KNN, PCA-KNN, LDA-KNN và PCA-LDA-KNN trên cùng fold cho phép xác định liệu cải thiện quan sát được đến từ PCA, LDA hay sự kết hợp tuần tự của hai phương pháp.

Thiết kế này cũng cho phép đánh giá sự đánh đổi giữa hiệu năng phân loại và chi phí truy vấn. Một cấu hình có số chiều thấp hơn có thể dự đoán nhanh hơn nhưng không nhất thiết đạt accuracy hoặc macro-F1 cao hơn. Vì vậy, kết luận được đưa ra riêng cho từng bộ dữ liệu thay vì giả định một cấu hình giảm chiều luôn tốt nhất.

VI. Dữ liệu và thiết lập thí nghiệm (Experiments)

Các thí nghiệm được xây dựng trên ba bộ dữ liệu có số lượng đặc trưng khác nhau, từ dữ liệu dạng bảng với số chiều tương đối thấp đến dữ liệu ảnh có không gian đặc trưng lớn.

Để đảm bảo khả năng so sánh giữa các phương pháp, cùng các fold của 3-fold stratified cross-validation, chuẩn hóa và cấu hình KNN được sử dụng cho tất cả các biến thể. Bốn cấu hình được xem xét gồm KNN trên dữ liệu gốc đã chuẩn hóa, PCA kết hợp KNN, LDA kết hợp KNN, và cấu hình PCA-LDA-KNN

VI.1. Dataset

Nghiên cứu sử dụng ba bộ dữ liệu công khai gồm **Breast Cancer Wisconsin**, **Labeled Faces in the Wild (LFW People)** và **MNIST**. Ba bộ dữ liệu có sự khác biệt đáng kể về số lượng mẫu, số lớp và đặc biệt là số chiều của không gian đặc trưng, cho phép khảo sát KNN trong các điều kiện dimensionality khác nhau.

Bảng 1: Thông tin các bộ dữ liệu sử dụng trong thí nghiệm

Dataset	Số mẫu	Số đặc trưng	Số lớp	Nguồn tải
Breast Cancer	569	30	2	<code>load_breast_cancer()</code>
LFW People	3023	1850	62	<code>fetch_lfw_people()</code>
MNIST	70000	784	10	<code>fetch_openml()</code>

Breast Cancer Wisconsin.

Bộ dữ liệu được tải thông qua hàm `load_breast_cancer()` của Scikit-learn. Dữ liệu bao gồm 569 mẫu với 30 đặc trưng số và hai lớp cần phân loại. Mỗi mẫu được biểu diễn trực tiếp dưới dạng một vector đặc trưng 30 chiều. Đây là bộ dữ liệu có số chiều thấp nhất trong ba dataset được sử dụng trong nghiên cứu.

LFW People.

Bộ dữ liệu khuôn mặt Labeled Faces in the Wild được tải bằng `fetch_lfw_people(min_faces_per_person=20,resize=0.4)`. Tham số `min_faces_per_person=20` giới hạn dữ liệu ở các cá nhân có ít nhất 20 ảnh, trong khi `resize=0.4` được sử dụng để giảm kích thước ảnh trước khi đưa vào pipeline. Sau bước tải và biểu diễn ảnh dưới dạng vector, dataset gồm 3023 mẫu, mỗi mẫu có 1850 đặc trưng và thuộc một trong 62 lớp danh tính. Đây là bộ dữ liệu có số chiều lớn nhất trong thí nghiệm.

MNIST.

MNIST được tải từ OpenML thông qua `fetch_openml('mnist_784', version=1, as_frame=False)`. Dataset gồm 70,000 ảnh chữ số viết tay thuộc 10 lớp từ 0 đến 9. Mỗi ảnh được biểu diễn dưới dạng vector gồm 784 giá trị đặc trưng, tương ứng với 28×28 pixel. Nhân sau khi tải được chuyển sang kiểu số nguyên `int64` trước khi thực hiện phân loại.

VII. Kết quả thí nghiệm (Results)

VII.1. Tổng hợp kết quả cross-validation

Bảng 2 trình bày giá trị trung bình và độ lệch chuẩn qua ba fold của bốn cấu hình KNN, PCA-KNN, LDA-KNN và PCA-LDA-KNN. Tất cả cấu hình sử dụng cùng các fold và cùng mô hình KNN với $k = 5$.

Dataset	Cấu hình	Accuracy	Macro-Precision	Macro-Recall	Macro-F1
Breast Cancer	normal	0.9649 $\pm$ 0.0152	0.9686 $\pm$ 0.0105	0.9567 $\pm$ 0.0211	0.9619 $\pm$ 0.0169
	pca	0.9613 $\pm$ 0.0132	0.9670 $\pm$ 0.0099	0.9510 $\pm$ 0.0177	0.9579 $\pm$ 0.0147
	lda	0.9631 $\pm$ 0.0229	0.9619 $\pm$ 0.0211	0.9591 $\pm$ 0.0284	0.9603 $\pm$ 0.0249
	pca_lda	0.9613 $\pm$ 0.0161	0.9637 $\pm$ 0.0176	0.9549 $\pm$ 0.0203	0.9582 $\pm$ 0.0176
LFW People	normal	0.3129 $\pm$ 0.0076	0.2908 $\pm$ 0.0426	0.1628 $\pm$ 0.0083	0.1738 $\pm$ 0.0158
	pca	0.3156 $\pm$ 0.0150	0.3221 $\pm$ 0.0165	0.1769 $\pm$ 0.0081	0.1954 $\pm$ 0.0110
	lda	0.0758 $\pm$ 0.0123	0.0516 $\pm$ 0.0048	0.0552 $\pm$ 0.0029	0.0478 $\pm$ 0.0037
	pca_lda	0.5174 $\pm$ 0.0125	0.5972 $\pm$ 0.0105	0.3488 $\pm$ 0.0007	0.3901 $\pm$ 0.0053
MNIST	normal	0.9440 $\pm$ 0.0014	0.9442 $\pm$ 0.0013	0.9432 $\pm$ 0.0014	0.9434 $\pm$ 0.0014
	pca	0.9580 $\pm$ 0.0004	0.9577 $\pm$ 0.0004	0.9575 $\pm$ 0.0004	0.9575 $\pm$ 0.0004
	lda	0.9141 $\pm$ 0.0018	0.9130 $\pm$ 0.0017	0.9129 $\pm$ 0.0018	0.9127 $\pm$ 0.0018
	pca_lda	0.9156 $\pm$ 0.0018	0.9145 $\pm$ 0.0018	0.9144 $\pm$ 0.0019	0.9142 $\pm$ 0.0019

Bảng 2: Kết quả 3-fold stratified cross-validation của bốn cấu hình. Giá trị được trình bày dưới dạng trung bình $\pm$ độ lệch chuẩn.

VII.2. Kết quả trên Breast Cancer

Trên Breast Cancer, KNN trên dữ liệu đã chuẩn hóa đạt accuracy trung bình cao nhất, 0.9649 ± 0.0152 , và macro-F1 cao nhất, 0.9619 ± 0.0169 . LDA-KNN đạt macro-recall cao nhất, 0.9591 ± 0.0284 , nhưng không vượt baseline về accuracy hoặc macro-F1. PCA-KNN và PCA-LDA-KNN cũng không tạo ra cải thiện trung bình so với baseline.

Chênh lệch accuracy giữa baseline và ba cấu hình giảm chiều chỉ nằm trong khoảng 0.0018 – 0.0035 , nhỏ hơn đáng kể so với độ lệch chuẩn giữa các fold. Ở cấp độ từng fold, PCA bằng baseline ở hai fold và thấp hơn ở fold còn lại; LDA và PCA-LDA chỉ vượt baseline ở một fold. Vì vậy, kết quả không hỗ trợ kết luận rằng một phương pháp giảm chiều cụ thể tạo ra lợi ích ổn định trên Breast Cancer.

VII.3. Kết quả trên LFW People

PCA-LDA-KNN đạt kết quả cao nhất trên LFW People ở cả bốn metric, với accuracy 0.5174 ± 0.0125 và macro-F1 0.3901 ± 0.0053 . So với baseline, cấu hình này tăng trung bình 0.2044 accuracy và 0.2162 macro-F1. PCA-LDA-KNN cũng đứng đầu ở cả ba fold, cho thấy thứ hạng quan sát được ổn định trong phạm vi phép đánh giá hiện tại.

PCA-KNN chỉ làm accuracy tăng trung bình 0.0026, với độ lệch chuẩn của chênh lệch là 0.0090; do đó chưa thể xem đây là cải thiện ổn định về accuracy. Tuy nhiên, macro-F1 tăng trung bình 0.0216 và cao hơn baseline ở cả ba fold. Ngược lại, LDA-KNN giảm mạnh accuracy xuống 0.0758 ± 0.0123 và macro-F1 xuống 0.0478 ± 0.0037 . Kết quả này cho thấy hiệu quả của LDA phụ thuộc đáng kể vào biểu diễn đầu vào: LDA trực tiếp hoạt động kém, trong khi LDA sau PCA tạo ra mức cải thiện lớn.

VII.4. Kết quả trên MNIST

PCA-KNN đạt kết quả cao nhất trên MNIST, với accuracy 0.9580 ± 0.0004 và macro-F1 0.9575 ± 0.0004 . So với baseline, PCA làm accuracy tăng trung bình 0.0140 và macro-F1 tăng 0.0141. PCA-KNN vượt baseline ở cả ba fold và có độ biến thiên nhỏ, cho thấy xu hướng cải thiện tương đối ổn định.

Hai cấu hình sử dụng LDA đều làm giảm hiệu năng. LDA-KNN đạt accuracy 0.9141 ± 0.0018 , còn PCA-LDA-KNN đạt 0.9156 ± 0.0018 . So với PCA-KNN, việc thêm LDA sau PCA làm accuracy giảm khoảng 0.0424 và macro-F1 giảm khoảng 0.0433. Kết quả cho thấy mức nén xuống 9 chiều của LDA không phù hợp bằng biểu diễn PCA 57 chiều đối với KNN trên MNIST.

VII.5. Thời gian truy vấn

Bảng 3 trình bày thời gian thực hiện `KNN.predict` trên mỗi mẫu và hệ số tăng tốc so với baseline. Phép đo được thực hiện trên fold đầu tiên, với tối đa 200 mẫu truy vấn và năm lần lặp; bảng báo cáo trung vị thời gian trên mỗi mẫu. Thời gian tiền xử lý và biến đổi mẫu mới không được tính vào phép đo này.

Giảm số chiều làm giảm thời gian truy vấn trên cả ba bộ dữ liệu. Mức tăng tốc rõ nhất xuất hiện trên LFW People và MNIST, nơi số chiều gốc lớn. Tuy nhiên, cấu hình nhanh nhất không nhất thiết đạt hiệu năng phân loại tốt nhất. Trên MNIST, PCA-KNN chậm hơn hai cấu hình sử dụng LDA nhưng đạt accuracy cao hơn khoảng 0.042. Vì vậy, thời gian truy vấn cần được xem xét cùng với lượng thông tin phân loại bị mất sau giảm chiều.

VIII. Thảo luận (Discussion)

VIII.1. Trả lời các câu hỏi nghiên cứu

RQ1: Cấu hình nào đạt hiệu năng tốt nhất trên từng bộ dữ liệu?

Trên Breast Cancer, baseline đạt accuracy và macro-F1 trung bình cao nhất, nhưng chênh lệch giữa các cấu hình nhỏ so với biến thiên giữa các fold. Vì vậy, kết quả phù hợp hơn với nhận

Dataset	Cấu hình	Số chiều KNN	ms/mẫu	Tăng tốc
Breast Cancer	normal	30	0.0435	1.00×
	pca	8	0.0177	2.46×
	lda	1	0.0171	2.55×
	pca_lda	1	0.0170	2.57×
LFW People	normal	1850	0.3270	1.00×
	pca	100	0.0398	8.22×
	lda	61	0.0302	10.82×
	pca_lda	61	0.0304	10.76×
MNIST	normal	784	3.1334	1.00×
	pca	57	0.4031	7.77×
	lda	9	0.2458	12.75×
	pca_lda	9	0.2433	12.88×

Bảng 3: Thời gian truy vấn của KNN trên các không gian biểu diễn.

định rằng các cấu hình có hiệu năng gần nhau, thay vì khẳng định baseline vượt trội. Trên LFW People, PCA-LDA-KNN đạt kết quả cao nhất ở cả bốn metric và ở cả ba fold. Trên MNIST, PCA-KNN là cấu hình tốt nhất và cũng đứng đầu ở cả ba fold.

RQ2: PCA, LDA và PCA-LDA làm thay đổi hiệu năng KNN như thế nào so với baseline?

Ảnh hưởng của PCA và LDA không thể tách rời khỏi đặc điểm dữ liệu. Trên Breast Cancer, không cấu hình giảm chiều nào cải thiện ổn định so với baseline. Trên LFW People, PCA đơn lẻ cải thiện macro-F1 nhưng gần như không thay đổi accuracy; LDA trực tiếp làm giảm mạnh cả hai metric; trong khi PCA-LDA cải thiện rõ rệt. Trên MNIST, PCA cải thiện cả accuracy và macro-F1, còn LDA làm giảm hiệu năng khi được dùng riêng hoặc sau PCA.

RQ3: Ảnh hưởng của giảm chiều có nhất quán giữa ba bộ dữ liệu không?

Kết quả không nhất quán giữa ba bộ dữ liệu. PCA-LDA phù hợp nhất với LFW People, PCA đơn lẻ phù hợp nhất với MNIST, còn Breast Cancer không cho thấy lợi ích ổn định từ giảm chiều. Do đó, không có cơ sở thực nghiệm để xem một cấu hình giảm chiều là lựa chọn mặc định cho KNN trên mọi loại dữ liệu.

VIII.2. Diễn giải các kết quả chính

LFW People là trường hợp cho thấy sự khác biệt lớn nhất giữa các pipeline. Dữ liệu có 1850 đặc trưng, 62 lớp và số mẫu trên mỗi lớp tương đối hạn chế. LDA trực tiếp trên dữ liệu chuẩn hóa cho kết quả rất thấp, trong khi PCA trước LDA làm accuracy tăng hơn 0.20 so với baseline. Một cách giải thích hợp lý là PCA tạo ra biểu diễn gọn hơn trước khi LDA tìm các hướng phân biệt lớp. Tuy nhiên, nghiên cứu không đo điều kiện số, hạng hiệu dụng hoặc độ ổn định của các trục LDA; vì vậy, kết quả chỉ chứng minh lợi ích thực nghiệm của thứ tự PCA-LDA trong thiết lập này, chưa chứng minh cơ chế nhân quả cụ thể.

Trên MNIST, PCA bảo toàn 57 hướng phương sai và đạt hiệu năng tốt hơn LDA với giới hạn tối

đa 9 chiều. LDA tối ưu khả năng phân tách lớp theo tiêu chí toàn cục, trong khi KNN dựa trên khoảng cách cục bộ giữa các mẫu. Việc nén xuống 9 chiều có thể không bảo toàn đầy đủ những biến thiên nội lớp như độ nghiêng, độ dày nét hoặc hình dạng cục bộ. Đây là một diễn giải phù hợp với kết quả, nhưng cần phân tích lân cận hoặc mẫu dự đoán sai để kiểm chứng trực tiếp.

Breast Cancer chỉ có 30 đặc trưng và baseline đã đạt hiệu năng cao. Trong trường hợp này, không gian gốc sau chuẩn hóa không tạo ra bất lợi đủ lớn để các bước giảm chiều đem lại cải thiện rõ rệt. Vì các chênh lệch nhỏ hơn độ biến thiên giữa fold, việc chọn pipeline chỉ dựa trên accuracy cao nhất ở một lần chia dữ liệu sẽ dẫn đến kết luận không ổn định.

VIII.3. Liên hệ với các nghiên cứu trước

Kết quả trên LFW People phù hợp về xu hướng với các nghiên cứu cho thấy quan hệ nearest-neighbor có thể trở nên kém phân biệt trong không gian nhiều chiều [2], [3], [4]. Tuy nhiên, nghiên cứu hiện tại chưa đo trực tiếp sự tập trung khoảng cách, relative contrast hoặc tỉ lệ giữa khoảng cách gần nhất và xa nhất. Vì vậy, không thể dùng kết quả phân loại để khẳng định PCA hoặc LDA đã khắc phục lời nguyền số chiều.

Hiệu quả của PCA trước LDA trên LFW People cũng phù hợp với hướng tiếp cận sử dụng PCA-LDA trong nhận dạng ảnh và khuôn mặt [8], [9]. Ngược lại, kết quả trên MNIST và Breast Cancer phù hợp với nhận định rằng ưu thế của PCA hoặc LDA không mang tính tuyệt đối [10]. PCA giữ phương sai, còn LDA tối ưu khả năng phân biệt lớp; cả hai tiêu chí đều không trực tiếp tối ưu cấu trúc lân cận mà KNN sử dụng.

VIII.4. Đánh đổi giữa hiệu năng và thời gian truy vấn

Kết quả query time cho thấy giảm chiều đem lại lợi ích tính toán rõ nhất khi số chiều ban đầu lớn. Trên LFW People, PCA-LDA-KNN vừa cải thiện hiệu năng vừa làm thời gian truy vấn giảm khoảng 10.76 lần, nên không xuất hiện đánh đổi bất lợi rõ ràng. Trên MNIST, LDA-KNN và PCA-LDA-KNN nhanh hơn PCA-KNN nhưng có accuracy thấp hơn đáng kể. PCA-KNN vì vậy cung cấp điểm cân bằng phù hợp hơn giữa hiệu năng phân loại và chi phí truy vấn trong các cấu hình đã khảo sát.

Các giá trị thời gian tuyệt đối không nên được khái quát sang môi trường khác. Phép đo chỉ thực hiện trên một fold, trong một phiên Colab và không bao gồm thời gian biến đổi một mẫu mới. Do đó, kết quả chủ yếu phản ánh chi phí tìm kiếm của brute-force KNN trên các số chiều khác nhau.

VIII.5. Giới hạn của kết quả

Thứ nhất, thí nghiệm chỉ sử dụng một lần 3-fold stratified cross-validation. Ba fold giúp đánh giá ổn định hơn một lần chia train-test, nhưng chưa đủ để ước lượng chắc chắn phân bố hiệu năng hoặc thực hiện kết luận thống kê mạnh. Đặc biệt, các chênh lệch nhỏ trên Breast Cancer không nên được diễn giải thành ưu thế của một pipeline.

Thứ hai, số thành phần PCA và LDA được cố định trước thay vì lựa chọn bằng nested cross-validation. Kết quả vì vậy chỉ mô tả các pipeline tại những số chiều đã chọn. Việc thay đổi số thành phần có thể làm thay đổi cả hiệu năng và thứ hạng giữa các cấu hình.

Thứ ba, nghiên cứu sử dụng implementation chuẩn của scikit-learn cho thí nghiệm cross-validation, trong khi notebook ban đầu chứa các implementation thủ công. Kết quả mới phản ánh pipeline chuẩn đã được dùng để tăng tính ổn định và khả năng tái tạo; chúng không thể được quy hoàn toàn cho thay đổi cách chia dữ liệu vì implementation cũng đã được thay đổi.

Cuối cùng, nghiên cứu chưa thực hiện confusion matrix, phân tích lỗi theo lớp hoặc đo trực tiếp đặc tính khoảng cách. Do đó, các giải thích về mất thông tin cục bộ, tính ổn định của LDA và lời nguyên số chiều vẫn là những diễn giải phù hợp với kết quả, không phải bằng chứng cơ chế trực tiếp.

Nhìn chung, kết quả hỗ trợ kết luận rằng tác động của giảm chiều đối với KNN phụ thuộc vào dữ liệu và mục tiêu của phép chiếu. PCA-LDA đem lại lợi ích rõ rệt trên LFW People, PCA đơn lẻ phù hợp hơn trên MNIST, còn Breast Cancer không cho thấy cải thiện ổn định. Giảm chiều cũng có thể giảm đáng kể query time, nhưng lợi ích tính toán cần được cân nhắc cùng với thay đổi về accuracy và macro-F1.

IX. Phân tích lỗi và hạn chế

Kết quả thực nghiệm cho thấy ảnh hưởng của PCA và LDA thay đổi đáng kể giữa các bộ dữ liệu. Tuy nhiên, nghiên cứu chưa lưu dự đoán theo từng mẫu hoặc confusion matrix cho từng fold. Vì vậy, phần này phân tích các xu hướng lỗi dựa trên kết quả tổng hợp của 3-fold stratified cross-validation và đặc điểm của các phép biến đổi; các cơ chế được nêu nên được hiểu là những cách giải thích hợp lý, chưa phải bằng chứng nhân quả trực tiếp.

IX.1. Phân tích xu hướng lỗi mô hình

- **Hiệu năng thấp của LDA đơn lẻ trên LFW People:** LDA-KNN chỉ đạt accuracy 0.0758 ± 0.0123 và macro-F1 0.0478 ± 0.0037 , thấp hơn rõ rệt so với KNN trên dữ liệu đã chuẩn hóa. Trong thí nghiệm này, LDA được cài đặt bằng `LinearDiscriminantAnalysis` của scikit-learn với `solver=svd`. Solver này không tính trực tiếp ma trận hiệp phương sai và không thực hiện phép nghịch đảo S_w^{-1} ; do đó, không thể quy kết kết quả thấp cho lỗi nghịch đảo ma trận phân tán nội lớp.

Một cách giải thích hợp lý là việc ước lượng các hướng phân biệt trực tiếp trong không gian đặc trưng cao trở nên khó khăn khi số mẫu của mỗi lớp còn hạn chế. LDA tối ưu sự phân tách dựa trên trung bình lớp và độ phân tán nội lớp, nên có thể không bảo toàn tốt cấu trúc lân cận mà KNN cần. Khi PCA được áp dụng trước để giảm dữ liệu xuống 100 chiều, PCA-LDA-KNN đạt accuracy 0.5174 ± 0.0125 và macro-F1 0.3901 ± 0.0053 . Kết quả này cho thấy bước PCA là thành phần trung gian quan trọng trên LFW People, nhưng chưa đủ để xác định duy nhất cơ chế tạo ra mức cải thiện.

- **Sự suy giảm của các cấu hình chứa LDA trên MNIST:** PCA-KNN đạt accuracy 0.9580 ± 0.0004 và macro-F1 0.9575 ± 0.0004 , trong khi PCA-LDA-KNN chỉ đạt lần lượt 0.9156 ± 0.0018 và 0.9142 ± 0.0019 . LDA tìm ma trận chiếu W nhằm tăng mức phân tách toàn cục giữa các lớp, thường được mô tả thông qua tiêu chí Fisher:

$$J(W) = \frac{\det(W^T S_b W)}{\det(W^T S_w W)}. \quad (4)$$

Trong khi đó, KNN phụ thuộc trực tiếp vào quan hệ khoảng cách cục bộ giữa các mẫu. Với MNIST có $C = 10$ lớp, LDA chỉ tạo được tối đa $C - 1 = 9$ thành phần, trong khi đầu vào sau PCA có 57 thành phần. Mức nén từ 57 xuống 9 chiều có thể làm mất một phần cấu trúc lân cận hữu ích cho KNN. Đây là cách giải thích phù hợp với kết quả quan sát được, nhưng cần thêm confusion matrix và phân tích lạng giềng theo từng lớp để kiểm chứng.

- **Khác biệt nhỏ và không ổn định trên Breast Cancer:** KNN trên dữ liệu đã chuẩn hóa đạt accuracy 0.9649 ± 0.0152 và macro-F1 0.9619 ± 0.0169 , cao hơn nhẹ so với PCA-LDA-KNN, đạt lần lượt 0.9613 ± 0.0161 và 0.9582 ± 0.0176 . Mức chênh lệch trung bình nhỏ hơn độ biến thiên giữa các fold, vì vậy chưa có bằng chứng cho thấy một cấu hình giảm chiều cải thiện ổn định trên bộ dữ liệu này. Kết quả cũng cho thấy việc nén dữ liệu hai lớp xuống một chiều bằng LDA không nhất thiết tạo ra lợi ích cho KNN.

IX.2. Hạn chế của các phương pháp giảm chiều

- **Giới hạn $C - 1$ của LDA:** Hạng của ma trận phân tán giữa các lớp S_b thỏa mãn

$$\text{rank}(S_b) \leq C - 1, \quad (5)$$

với C là số lớp. Vì vậy, LDA chỉ có thể tạo tối đa $C - 1$ thành phần. Giới hạn này đặc biệt mạnh trên Breast Cancer, nơi dữ liệu có hai lớp và đầu ra LDA chỉ còn một chiều, cũng như trên MNIST, nơi đầu ra tối đa là chín chiều. Việc nén mạnh có thể loại bỏ thông tin hữu ích cho quan hệ lân cận của KNN.

- **Giới hạn của phép chiếu tuyến tính:** PCA và LDA đều tạo ra các phép chiếu tuyến tính. Do đó, chúng không mô hình hóa trực tiếp các cấu trúc phi tuyến phức tạp có thể xuất hiện trong ảnh khuôn mặt hoặc chữ viết tay. Đây là một giới hạn về khả năng biểu diễn, nhưng nghiên cứu hiện tại không so sánh với phương pháp giảm chiều phi tuyến hoặc mô hình học sâu nên không thể kết luận về mức chênh lệch hiệu năng với các nhóm phương pháp đó.

IX.3. Hạn chế của thiết lập thí nghiệm

- **Chưa đo trực tiếp hiện tượng tập trung khoảng cách:** Nghiên cứu đánh giá ảnh hưởng của giảm chiều thông qua hiệu năng phân loại, nhưng chưa đo các đại lượng như relative contrast hoặc tỉ lệ giữa khoảng cách gần nhất và xa nhất. Vì vậy, kết quả không đủ để kết luận PCA hoặc LDA đã loại bỏ lời nguyên số chiều; chúng chỉ cho thấy hiệu năng KNN thay đổi theo cấu hình biểu diễn.
- **Số fold và số lần lặp còn hạn chế:** Thí nghiệm sử dụng 3-fold stratified cross-validation với cùng các fold cho bốn cấu hình. Thiết lập này đáng tin cậy hơn một lần chia train/test, nhưng mới chỉ gồm ba phép đánh giá và chưa sử dụng repeated stratified cross-validation. Do đó, độ lệch chuẩn báo cáo chỉ phản ánh biến thiên giữa ba fold của một lần chia cross-validation.
- **Siêu tham số được cố định trước:** Nghiên cứu cố định $k = 5$ cho KNN và số thành phần PCA lần lượt là 8, 100 và 57 cho Breast Cancer, LFW People và MNIST. Các giá trị

này chưa được lựa chọn bằng nested cross-validation. Vì vậy, kết quả dùng để so sánh bốn cấu hình tại các thiết lập đã chọn, không chứng minh rằng mỗi cấu hình đã đạt hiệu năng tối ưu.

- **Phân tích lỗi chưa thực hiện ở mức mẫu và mức lớp:** Các kết quả hiện tại gồm accuracy, macro-precision, macro-recall và macro-F1 tổng hợp. Nghiên cứu chưa báo cáo confusion matrix, chỉ số theo từng lớp hoặc các mẫu thường xuyên bị phân loại sai. Hạn chế này đặc biệt đáng chú ý trên LFW People vì số lớp lớn và phân bố mẫu theo lớp không đồng đều.
- **Phạm vi phép đo thời gian truy vấn:** Thời gian truy vấn được đo trên bước `KNN.predict` sau khi dữ liệu đã được biến đổi và chỉ sử dụng tối đa 200 mẫu ở fold đầu tiên. Phép đo này cho thấy chi phí tìm láng giềng giảm khi số chiều nhỏ hơn, nhưng chưa phản ánh thời gian suy diễn đầu cuối bao gồm chuẩn hóa, PCA và LDA.

X. Tái lập kết quả và mã nguồn (Replicate the results)

Mã nguồn và các bảng kết quả được lưu tại repository: <https://github.com/AIVIETNAM-AIO-Tuan/curse-of-dimensionality>. Thí nghiệm cross-validation được thực hiện bằng file `cv_ablation_results_only.py`. Notebook `Main.ipynb` lưu phiên bản thí nghiệm ban đầu và không phải nguồn tạo ra các số liệu cross-validation được báo cáo trong nghiên cứu này.

Script sử dụng `StandardScaler`, `PCA`, `LinearDiscriminantAnalysis` và `KNeighborsClassifier` của scikit-learn. Trong mỗi fold, bước chuẩn hóa và các phép giảm chiều chỉ được fit trên training fold, sau đó mới được dùng để biến đổi test fold. Bốn cấu hình `normal`, `pca`, `lda` và `pca_lda` được đánh giá trên cùng các fold.

X.1. Cài đặt môi trường

Các thư viện cần thiết được liệt kê trong file `requirements.txt`. Từ thư mục chứa mã nguồn, cài đặt môi trường bằng lệnh:

```
pip install -r requirements.txt
```

Ba bộ dữ liệu được tải tự động bằng scikit-learn và OpenML. Người dùng không cần tải dữ liệu thủ công. LFW People cần kết nối Internet trong lần tải đầu tiên; MNIST được lấy từ OpenML.

X.2. Chạy lại thí nghiệm

Các số liệu trong báo cáo được tạo bằng chế độ `quick`, tương ứng với một lần 3-fold stratified cross-validation:

```
python cv_ablation_results_only.py \  
    --mode quick \  
    --datasets breast_cancer lfw mnist \  
    --output-dir cv_results
```

Trong Google Colab, thêm dấu ! trước lệnh python:

```
!python cv_ablation_results_only.py \  
    --mode quick \  
    --datasets breast_cancer lfw mnist \  
    --output-dir cv_results
```

Script cố định `random_state=42`, sử dụng ba fold, $k = 5$, trọng số đồng đều, khoảng cách Euclidean và thuật toán tìm kiếm brute force. Số thành phần PCA lần lượt là 8, 100 và 57 cho Breast Cancer, LFW People và MNIST; số thành phần LDA tương ứng là 1, 61 và 9.

X.3. Các file kết quả

Sau khi hoàn tất, thư mục `cv_results` chứa bốn file chính:

- `cv_fold_results.csv`: accuracy, macro-precision, macro-recall và macro-F1 của từng cấu hình trên từng fold;
- `cv_summary.csv`: giá trị trung bình và độ lệch chuẩn của các metric qua ba fold;
- `cv_delta_vs_normal.csv`: chênh lệch paired giữa từng cấu hình giảm chiều và baseline trên cùng các fold;
- `query_time.csv`: thời gian `KNN.predict` trên mỗi mẫu và hệ số tăng tốc so với baseline.

Các bảng trong phần kết quả được tổng hợp từ những file CSV này. Thời gian truy vấn chỉ đo bước `KNN.predict` trên dữ liệu đã được biến đổi, sử dụng tối đa 200 mẫu ở fold đầu tiên, một lượt khởi động và năm lần lặp. Vì vậy, phép đo không bao gồm thời gian chuẩn hóa hoặc biến đổi PCA/LDA.

X.4. Lưu ý về khả năng tái lập

Với cùng phiên bản Python, NumPy và scikit-learn, các metric phân loại dự kiến tái lập được do fold và các random seed đã được cố định. Sai khác nhỏ vẫn có thể xuất hiện do phiên bản thư viện, nguồn dữ liệu OpenML hoặc phép tính số trên môi trường khác. Thời gian truy vấn phụ thuộc trực tiếp vào CPU, tải hệ thống và phiên chạy nên chỉ nên được đối chiếu theo xu hướng tương đối giữa các cấu hình, không yêu cầu khớp tuyệt đối với số mili giây trong báo cáo.

XI. Kết luận và hướng nghiên cứu tiếp theo

XI.1. Kết luận

Nghiên cứu đã so sánh bốn cấu hình gồm KNN trên dữ liệu đã chuẩn hóa, PCA-KNN, LDA-KNN và PCA-LDA-KNN trên ba bộ dữ liệu Breast Cancer, LFW People và MNIST. Các cấu hình được đánh giá bằng 3-fold stratified cross-validation thông qua accuracy, macro-precision, macro-recall và macro-F1. Thời gian truy vấn của KNN cũng được đo để xem xét sự đánh đổi giữa hiệu năng phân loại và chi phí tìm kiếm láng giềng.

Đối với RQ1, kết quả cho thấy cấu hình tốt nhất phụ thuộc vào bộ dữ liệu. Trên Breast Cancer, KNN trên dữ liệu chuẩn hóa đạt accuracy trung bình cao nhất là 0.9649 ± 0.0152 và macro-F1 cao nhất là 0.9619 ± 0.0169 . Tuy nhiên, chênh lệch giữa các cấu hình nhỏ so với biến thiên giữa các fold, nên chưa có bằng chứng cho thấy một pipeline vượt trội ổn định. Trên LFW People, PCA-LDA-KNN đạt kết quả cao nhất với accuracy 0.5174 ± 0.0125 và macro-F1 0.3901 ± 0.0053 . Trên MNIST, PCA-KNN đạt kết quả tốt nhất với accuracy 0.9580 ± 0.0004 và macro-F1 0.9575 ± 0.0004 .

Đối với RQ2, PCA và LDA tạo ra những ảnh hưởng khác nhau tùy theo dữ liệu và thứ tự áp dụng. Trên Breast Cancer, không cấu hình giảm chiều nào cải thiện ổn định so với baseline. Trên LFW People, PCA đơn lẻ gần như không thay đổi accuracy nhưng cải thiện macro-F1, trong khi LDA trực tiếp làm giảm mạnh hiệu năng. Khi PCA được áp dụng trước LDA, cả accuracy và macro-F1 đều tăng rõ rệt. Trên MNIST, PCA cải thiện hiệu năng so với baseline, nhưng LDA làm giảm accuracy và macro-F1 khi được sử dụng riêng hoặc sau PCA.

Đối với RQ3, ảnh hưởng của giảm chiều không nhất quán giữa ba bộ dữ liệu. PCA-LDA phù hợp nhất với LFW People, PCA đơn lẻ phù hợp nhất với MNIST, còn Breast Cancer không cho thấy lợi ích ổn định từ giảm chiều. Kết quả này cho thấy không có cơ sở để giả định rằng một pipeline giảm chiều luôn tối ưu cho KNN trên mọi loại dữ liệu.

Kết quả query time cho thấy giảm số chiều làm giảm chi phí tìm kiếm của brute-force KNN. PCA-LDA-KNN nhanh hơn baseline khoảng 10.76 lần trên LFW People, trong khi PCA-KNN nhanh hơn khoảng 7.77 lần trên MNIST. Tuy nhiên, cấu hình nhanh nhất không nhất thiết đạt hiệu năng phân loại cao nhất. Trên MNIST, hai cấu hình sử dụng LDA có thời gian truy vấn thấp hơn PCA-KNN nhưng làm accuracy giảm hơn 0.04. Vì vậy, lợi ích tính toán phải được đánh giá đồng thời với lượng thông tin phân loại bị mất.

Các kết quả hiện tại chưa đủ để kết luận rằng PCA hoặc LDA đã khắc phục lời nguyền số chiều. Nghiên cứu chưa đo trực tiếp sự tập trung khoảng cách hoặc thay đổi số chiều đầu vào một cách có kiểm soát. Kết quả chỉ chứng minh rằng giảm chiều có thể cải thiện, không làm thay đổi đáng kể hoặc làm giảm hiệu năng của KNN tùy theo dữ liệu, số chiều được giữ lại và tiêu chí tối ưu của phép chiếu.

XI.2. Hướng nghiên cứu tiếp theo

Trước hết, độ ổn định của kết quả cần được đánh giá bằng repeated stratified cross-validation với nhiều lần lặp. Kết quả nên tiếp tục được báo cáo dưới dạng trung bình và độ lệch chuẩn,

đồng thời sử dụng phép so sánh paired trên cùng các fold khi số lần lặp đủ lớn. Điều này đặc biệt cần thiết đối với Breast Cancer, nơi chênh lệch giữa các pipeline hiện nhỏ hơn biến thiên giữa các fold.

Số thành phần PCA và LDA cần được lựa chọn bằng nested cross-validation hoặc một tiêu chí xác định trước, thay vì cố định ở một giá trị duy nhất. Đối với PCA, có thể khảo sát đồng thời số thành phần cụ thể và các ngưỡng phương sai được giải thích. Thiết kế này sẽ giúp phân biệt ảnh hưởng của bản thân phương pháp giảm chiều với ảnh hưởng của mức nén đã lựa chọn.

Mối liên hệ với lời nguyên số chiều cần được kiểm tra trực tiếp bằng cách thay đổi số chiều đầu vào theo nhiều mức có kiểm soát và theo dõi các đại lượng như relative contrast hoặc tỉ lệ giữa khoảng cách gần nhất và xa nhất [2], [3], [4]. Qua đó, nghiên cứu có thể xác định liệu thay đổi hiệu năng KNN có thực sự đi kèm với thay đổi về khả năng phân biệt khoảng cách hay không.

Phân tích lỗi cần được bổ sung bằng confusion matrix, metric theo từng lớp và các mẫu dự đoán sai tiêu biểu. Trên MNIST, việc xác định các cặp chữ số thường bị nhầm sau bước LDA có thể làm rõ loại thông tin bị mất. Trên LFW People, phân tích theo lớp sẽ cho biết mức cải thiện macro-F1 có phân bố rộng giữa các lớp hay chỉ tập trung ở một số lớp nhất định.

Cuối cùng, đánh giá thời gian cần được mở rộng sang thời gian dự đoán đầu cuối, bao gồm cả bước chuẩn hóa và phép biến đổi PCA hoặc LDA cho mẫu mới. Các phép đo cũng cần được lặp lại trên cùng phần cứng và trong nhiều phiên chạy để giảm ảnh hưởng của tải hệ thống. Khi đó, nghiên cứu có thể đánh giá đầy đủ hơn sự đánh đổi giữa hiệu năng phân loại, số chiều biểu diễn, thời gian tiền xử lý và thời gian tìm kiếm láng giềng.

XII. Tài liệu tham khảo

- [1] T. M. Cover et al., “Nearest neighbor pattern classification”, *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967. DOI: 10.1109/TIT.1967.1053964
- [2] K. S. Beyer et al., “When is “nearest neighbor” meaningful?”, in *Database Theory—ICDT’99*, ser. Lecture Notes in Computer Science, vol. 1540, Springer, 1999, pp. 217–235. DOI: 10.1007/3-540-49257-7_15
- [3] C. C. Aggarwal et al., “On the surprising behavior of distance metrics in high dimensional space”, in *Database Theory—ICDT 2001*, ser. Lecture Notes in Computer Science, vol. 1973, Springer, 2001, pp. 420–434. DOI: 10.1007/3-540-44503-X_27
- [4] D. François et al., “The concentration of fractional distances”, *IEEE Transactions on Knowledge and Data Engineering*, vol. 19, no. 7, pp. 873–886, 2007. DOI: 10.1109/TKDE.2007.1037
- [5] K. Pearson, “Liii. on lines and planes of closest fit to systems of points in space”, *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, vol. 2, no. 11, pp. 559–572, 1901. DOI: 10.1080/14786440109462720
- [6] H. Hotelling, “Analysis of a complex of statistical variables into principal components”, *Journal of Educational Psychology*, vol. 24, no. 6, pp. 417–441, 1933. DOI: 10.1037/h0071325
- [7] R. A. Fisher, “The use of multiple measurements in taxonomic problems”, *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936. DOI: 10.1111/j.1469-1809.1936.tb02137.x
- [8] D. L. Swets et al., “Using discriminant eigenfeatures for image retrieval”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 18, no. 8, pp. 831–836, 1996. DOI: 10.1109/34.531802
- [9] P. N. Belhumeur et al., “Eigenfaces vs. fisherfaces: Recognition using class specific linear projection”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 19, no. 7, pp. 711–720, 1997. DOI: 10.1109/34.598228
- [10] A. M. Martínez et al., “PCA versus LDA”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 23, no. 2, pp. 228–233, 2001. DOI: 10.1109/34.908974
- [11] T. Taufiqurrahman et al., “Analysis of dimensional reduction effect on k-nearest neighbor classification method”, *Sinkron: Jurnal dan Penelitian Teknik Informatika*, vol. 5, no. 2B, pp. 222–230, 2021. DOI: 10.33395/sinkron.v6i1.11234 [Online]. Available: <https://jurnal.polgan.ac.id/index.php/sinkron/article/view/11234>
- [12] C. Li et al., “Using the k-nearest neighbor algorithm for the classification of lymph node metastasis in gastric cancer”, *Computational and Mathematical Methods in Medicine*, vol. 2012, p. 876545, 2012. DOI: 10.1155/2012/876545 [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC3488413/>
- [13] L. Lamport, *LaTeX: A Document Preparation System: User’s Guide and Reference Manual*, 2nd ed. Addison-Wesley, 1994, ISBN: 978-0201529838.
- [14] LaTeX Project. “Latex – a document preparation system”, Accessed: Apr. 17, 2026. [Online]. Available: <https://www.latex-project.org/>

- [15] Overleaf. “Overleaf, online latex editor”, Accessed: Apr. 17, 2026. [Online]. Available: <https://www.overleaf.com/>
- [16] Overleaf. “Bibliography management with bibtex”, Accessed: Apr. 17, 2026. [Online]. Available: https://www.overleaf.com/learn/latex/Bibliography_management_with_bibtex
- [17] Overleaf Docs. “Adding citations and references”, Accessed: Apr. 17, 2026. [Online]. Available: <https://docs.overleaf.com/citing-and-references/adding-citations-and-references>
- [18] R. Cangelosi et al., “Component retention in principal component analysis with application to cdna microarray data”, *Biology Direct*, vol. 2, no. 1, p. 2, 2007. DOI: 10.1186/1745-6150-2-2
- [19] R. Kohavi, “A study of cross-validation and bootstrap for accuracy estimation and model selection”, in *Proceedings of the Fourteenth International Joint Conference on Artificial Intelligence*, vol. 2, 1995, pp. 1137–1145.
- [20] C. Nadeau et al., “Inference for the generalization error”, *Machine Learning*, vol. 52, pp. 239–281, 2003. DOI: 10.1023/A:1024068626366
- [21] J. H. Friedman, “Regularized discriminant analysis”, *Journal of the American Statistical Association*, vol. 84, no. 405, pp. 165–175, 1989. DOI: 10.1080/01621459.1989.10478752
- [22] O. Ledoit et al., “A well-conditioned estimator for large-dimensional covariance matrices”, *Journal of Multivariate Analysis*, vol. 88, no. 2, pp. 365–411, 2004. DOI: 10.1016/S0047-259X(03)00096-4
- [23] R. Weber et al., “A quantitative analysis and performance study for similarity-search methods in high-dimensional spaces”, in *Proceedings of the 24th International Conference on Very Large Data Bases*, Morgan Kaufmann, 1998, pp. 194–205.
- [24] C. C. Aggarwal, “On the effects of dimensionality reduction on high dimensional similarity search”, in *Proceedings of the Twentieth ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems*, ACM, 2001.

Phụ lục

1. **AIVIETNAM:** Thông tin về AIVIETNAM có thể đọc thêm tại [đây](#).
2. **GitHub Repository:** [Repository](#).
3. **Demo Video / Presentation:** [Video](#).